UNIVERSIDAD DEL VALLE DE GUATEMALA

DATA SCIENCE - 40

Erick Marroquin



Proyecto 2 Resultados parciales y visualizaciones técnicas

Ihan Marroquin 23108

Diego Patzan 23525

Milton Polanco 23471

GUATEMALA, 12 de octubre del 2026

Informe final

https://github.com/Ihan-Marroquin/Proyecto_data

Resumen

Este informe documenta la segunda etapa del proyecto de identificación visual de mosquitos. Se conservaron los hallazgos del análisis exploratorio y se implementó un flujo reproducible que recorta cada mosquito con su caja delimitadora, preserva la relación de aspecto, extrae descriptores HOG y HSV, ajusta tres familias de clasificadores y compara su rendimiento en una partición de prueba estratificada. Para esta corrida se usaron **2,728** imágenes de las **10,357** documentadas en el análisis exploratorio. Los resultados se consideran parciales porque los modelos son líneas base de aprendizaje automático y no una arquitectura profunda afinada.

El mejor resultado parcial correspondió a **Bosque aleatorio**, con F1 macro de **0.267** y exactitud balanceada de **0.284**. La exactitud global se reporta, pero no dirige la selección debido a la relación aproximada de 98 a 1 entre la clase mayoritaria y la minoritaria.

1 Introducción

Mosquito Alert reúne fotografías tomadas por ciudadanía en condiciones reales. Esa fuente amplía la cobertura de vigilancia, pero también introduce variaciones de fondo, iluminación, resolución, posición y escala. El problema de esta etapa consiste en determinar hasta qué punto modelos computacionalmente accesibles pueden separar seis etiquetas taxonómicas sin ocultar el desempeño de Aegypti y Anopheles, que cuentan con pocos ejemplos.

La aplicación construida permite cargar una fotografía, delimitar el mosquito, consultar cada modelo por separado o compararlos, explorar las variables limpias y mostrar u ocultar las métricas. La salida es experimental y requiere validación experta antes de cualquier uso en vigilancia entomológica.

2 Objetivos

Objetivo general. Construir y comparar modelos reproducibles que clasifiquen imágenes del AI Mosquito Alert Challenge 2023 y presentar sus resultados en visualizaciones técnicas y una aplicación interactiva.

Objetivo específico	Evidencia de cumplimiento
Preparar entradas de imagen sin deformar la morfología.	Recorte por caja, corrección EXIF y letterbox de 96 x 96.
Evaluar varios algoritmos con ajuste de parámetros.	Tres familias y dos configuraciones por familia.
Comparar calidad, velocidad y errores por clase.	F1 macro, exactitud balanceada, recall, matrices y latencia.
Permitir exploración y clasificación interactiva.	Aplicación Streamlit con tres secciones.

3 Marco teórico y revisión bibliográfica

Las redes convolucionales aprenden jerarquías de textura y forma directamente de los píxeles. Motta et al. (2019) compararon LeNet, AlexNet y GoogLeNet sobre 4,056 imágenes de tres especies y obtuvieron su mejor resultado de prueba con GoogLeNet. Park et al. (2020) mostraron que las redes profundas también permiten relacionar activaciones con rasgos morfológicos en ocho especies.

En fotografías de ciencia ciudadana, Pataki et al. (2021) entrenaron ResNet50 con imágenes de Mosquito Alert y reportaron AUC ROC de 0.96 para reconocer Aedes albopictus. Adhane, Dehshibi y Masip (2021) aplicaron transferencia de aprendizaje y Grad-CAM a datos del mismo proyecto, con especial atención a bandas claras en patas, abdomen y tórax. Zhao et al. (2022) ampliaron la comparación a CNN y Transformers y mostraron el potencial de Swin Transformer en un conjunto balanceado y controlado. Estas investigaciones justifican una CNN transferida como siguiente fase, pero también muestran que el tipo de imagen, el equilibrio y el protocolo de validación impiden comparar porcentajes de forma directa entre estudios.

Para obtener resultados parciales en CPU, el proyecto usa HOG como representación de contornos y orientaciones locales, junto con histogramas HSV para color. La regresión logística y la SVM lineal establecen baselines discriminativos; el bosque aleatorio aporta una relación no lineal sobre los descriptores de color. Todos los modelos usan ponderación de clases cuando el algoritmo lo permite.

4 Metodología

4.1 Datos y preprocesamiento

Clase	Entrenamiento	Validación	Prueba
aegypti	8	2	2
albopictus	600	185	185
anopheles	13	3	3
culex	600	179	179
culiseta	119	25	25
japonicus-koreicus	74	16	16

La división usa una semilla fija de 42 y estratificación. La porción de entrenamiento se limita a 600 imágenes por clase para reducir costo y acercar el aporte de las clases mayoritarias, mientras validación y prueba conservan la distribución de la muestra de modelado. Se ajustaron 1 cajas fuera de límites contra el ancho y alto reales de la imagen. El CSV completo se preservó por separado y la selección de entradas disponibles queda declarada en los metadatos de ejecución.

4.2 Selección y ajuste

Modelo	Configuración	Características	F1 macro validación
Bosque aleatorio	500 árboles, hoja=1	color	0.271
Bosque aleatorio	300 árboles, hoja=2	color	0.268
Regresión logística	C=0.5	combined	0.235
Regresión logística	C=2.0	combined	0.226
SVM lineal	C=0.1	combined	0.220
SVM lineal	C=0.5	combined	0.220

Cada familia se seleccionó por F1 macro en validación. Luego se volvió a entrenar la configuración ganadora con entrenamiento más validación y se evaluó una sola vez en prueba. Este procedimiento reduce el riesgo de elegir parámetros usando el mismo conjunto con el que se informa el resultado.

5 Resultados y análisis

Modelo	F1 macro	Exactitud balanceada	Exactitud	ms/imagen	MB
Bosque aleatorio	0.267	0.284	0.756	0.83	10.95
Regresión logística	0.207	0.203	0.524	0.03	0.08
SVM lineal	0.198	0.193	0.500	0.03	0.12

Bosque aleatorio obtuvo la mayor F1 macro. La distancia entre exactitud global y exactitud balanceada muestra cuánto puede favorecer la primera a Albopictus y Culex. Por ello, la interpretación principal se realiza con promedios macro y recall por clase. El tiempo por imagen corresponde únicamente a la predicción de características ya extraídas; la lectura y el preprocesamiento agregan latencia en la aplicación.

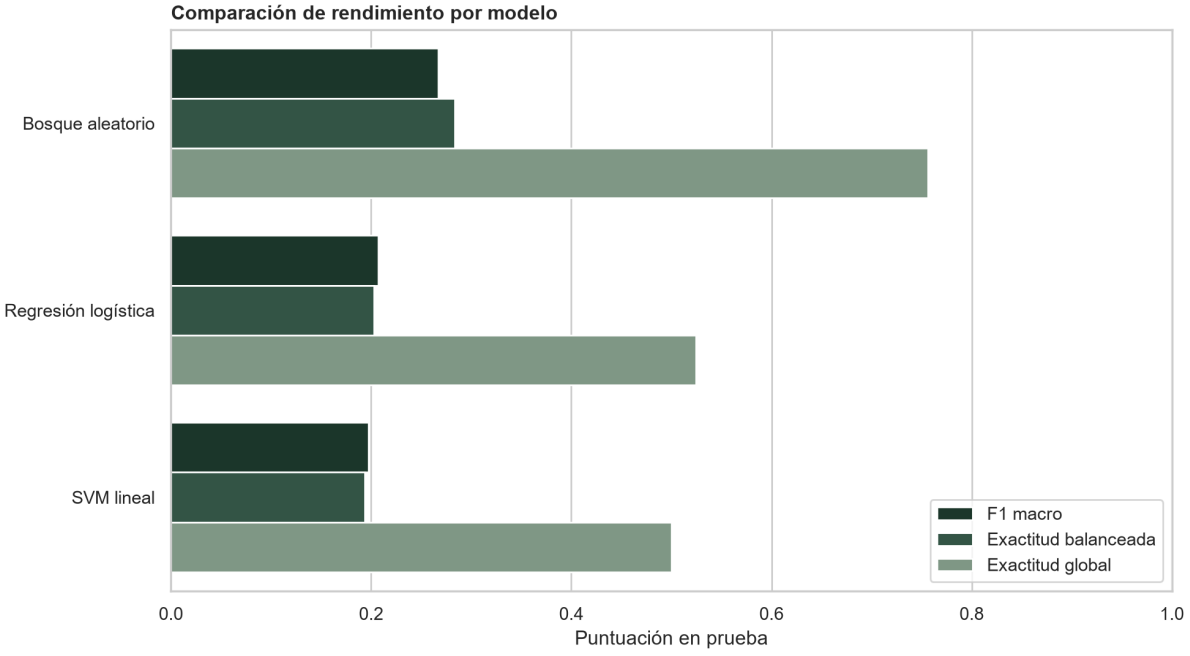


Figura 1. Comparación de las métricas principales en prueba.



Figura 2. Recall por clase y por modelo.

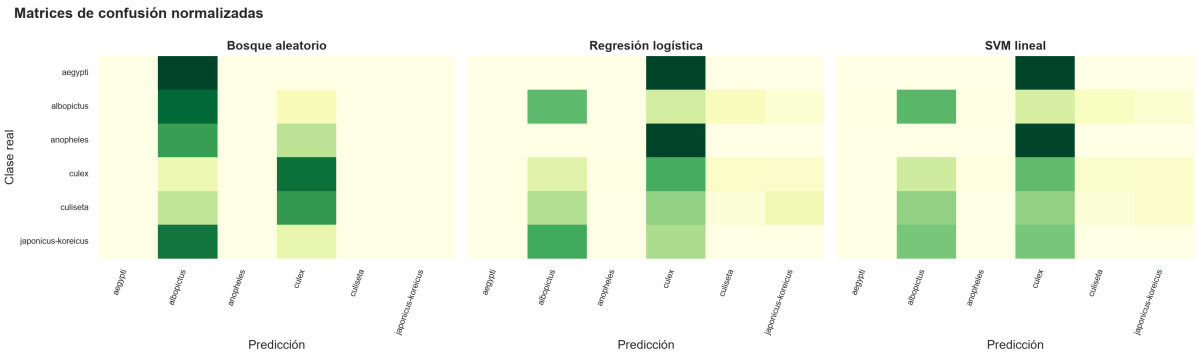


Figura 3. Matrices de confusión normalizadas por fila.

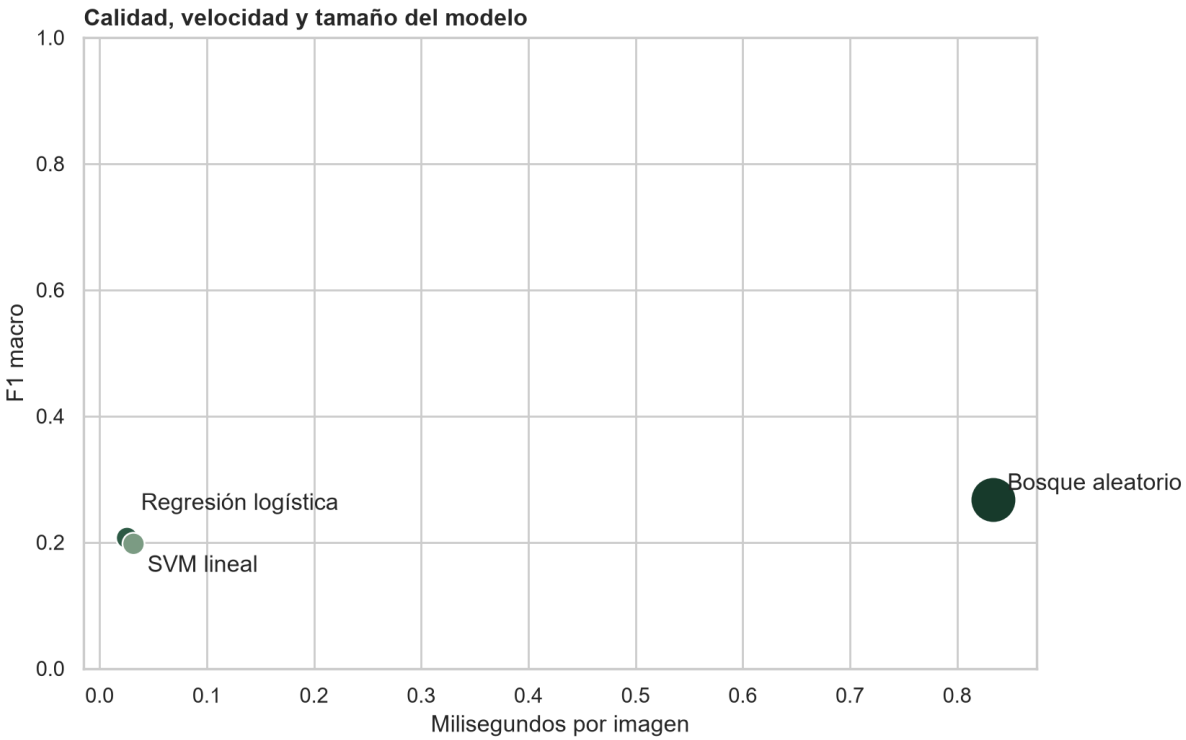


Figura 4. Relación entre calidad, velocidad y tamaño del artefacto.

5.1 Errores y clases minoritarias

En el modelo seleccionado, el recall más bajo correspondió a **aegypti** (0.000) y el más alto a **albopictus** (0.870). El soporte de prueba debe leerse junto con estos valores: Aegypti y Anopheles tienen pocos casos y, por tanto, unos cuantos aciertos o errores cambian la métrica de forma sustancial. Las matrices de confusión permiten ver si los errores se concentran en clases visualmente cercanas o simplemente se desplazan hacia las clases frecuentes.

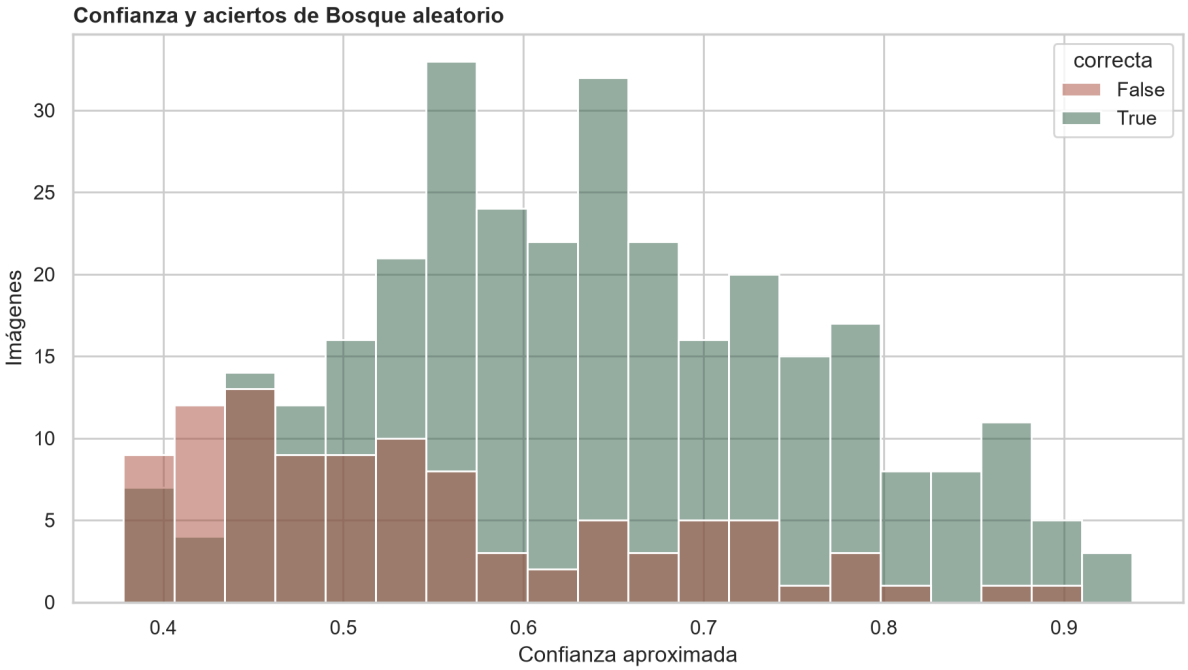


Figura 5. Confianza aproximada en predicciones correctas e incorrectas.

6 Aplicación

La aplicación Streamlit contiene tres secciones. Clasificar acepta una imagen, permite delimitar el mosquito y muestra las probabilidades o puntajes normalizados de uno o todos los modelos. Explorar datos presenta filtros y gráficas interactivas sobre clases, resolución y proporción de la caja. Comparar modelos muestra métricas, recall por clase y errores; un interruptor permite ocultar esa información. El código carga los mismos artefactos y funciones de preprocesamiento usados en entrenamiento.

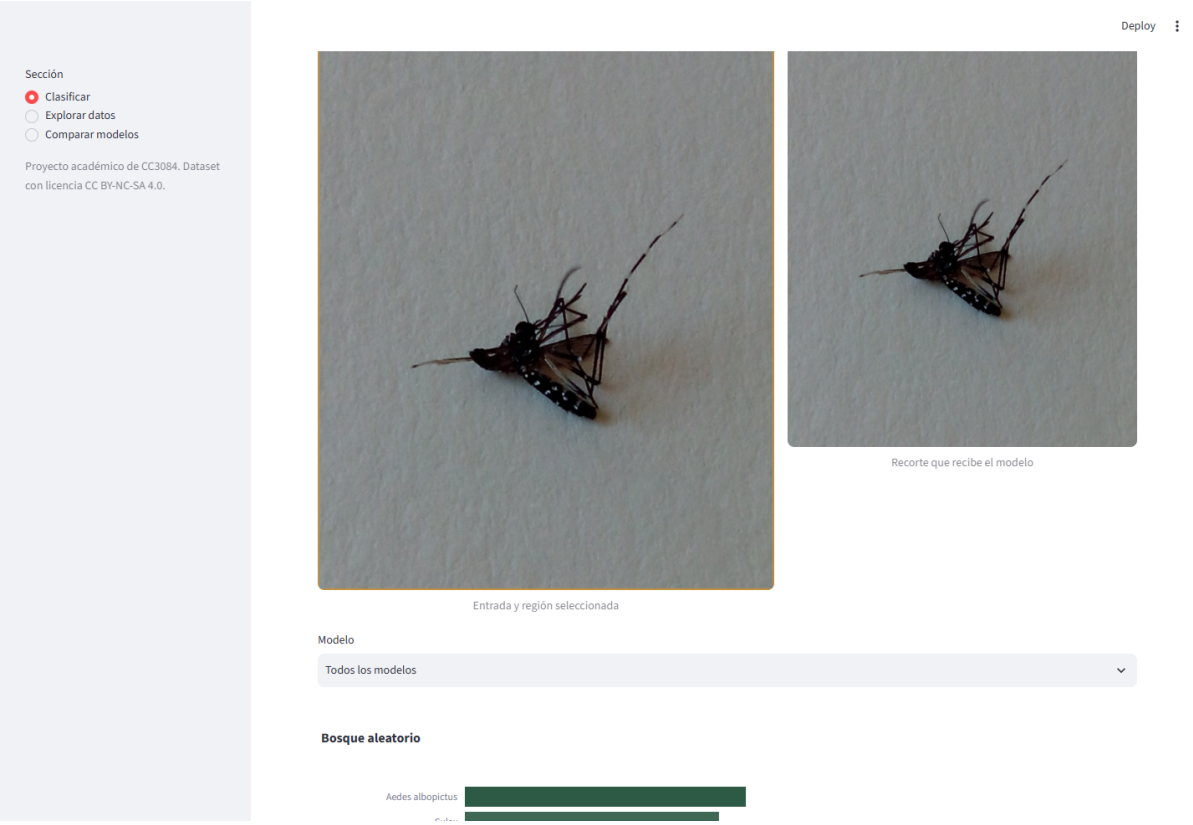


Figura 6. Vista de clasificación y comparación de modelos.



Figura 7. Vista interactiva de rendimiento.

7 Limitaciones

Los resultados no constituyen una estimación clínica ni una validación de campo. El conjunto combina etiquetas a nivel de especie, género y complejo de especies. La muestra parcial del archivo oficial, el número reducido de Aegypti y Anopheles, y el uso de descriptores manuales limitan la generalización. Además, el recorte de la caja usa una anotación conocida durante entrenamiento; una aplicación final debería incorporar detección automática o solicitar explícitamente la región de interés.

La siguiente iteración debe evaluar transferencia de aprendizaje con una red ligera, aumentación dirigida, focal loss o muestreo balanceado, calibración de probabilidades y validación repetida. También conviene comparar la clasificación del recorte contra la fotografía completa para medir la dependencia de la caja delimitadora.

8 Conclusiones

• El proyecto implementó un flujo reproducible desde la anotación hasta la predicción y corrigió 1 cajas fuera de límites de la muestra únicamente durante el recorte.

• La comparación seleccionó Bosque aleatorio como mejor baseline por F1 macro, con 0.267 en prueba.

• Las métricas por clase mostraron diferencias que la exactitud global no refleja; por eso la evaluación debe mantener promedios macro y matrices normalizadas.

• Las visualizaciones técnicas relacionan rendimiento, errores, latencia y tamaño, en lugar de presentar una sola cifra de precisión.

• La aplicación permite explorar datos limpios, clasificar imágenes y comparar u ocultar resultados, pero conserva advertencias sobre el alcance experimental.

• Los baselines cumplen la etapa de resultados parciales y dejan una referencia verificable para entrenar una CNN transferida en la siguiente iteración.

Referencias

Adhane, G., Dehshibi, M. M., & Masip, D. (2021). A deep convolutional neural network for classification of Aedes albopictus mosquitoes. IEEE Access, 9, 72681-72690. https://doi.org/10.1109/ACCESS.2021.3079700

Bartumeus, F., Garriga, J., Falk, M., & Mosquito Alert Expert Community. (2025). AI Mosquito Alert Challenge Dataset 2023 (Version v1) [Data set]. Zenodo. https://doi.org/10.5281/zenodo.15063886

Motta, D., Santos, A. A. B., Winkler, I., et al. (2019). Application of convolutional neural networks for classification of adult mosquitoes in the field. PLOS ONE, 14(1), e0210829. https://doi.org/10.1371/journal.pone.0210829

Park, J., Kim, D. I., Choi, B., Kang, W., & Kwon, H. W. (2020). Classification and morphological analysis of vector mosquitoes using deep convolutional neural networks. Scientific Reports, 10, 1012. https://doi.org/10.1038/s41598-020-57875-1

Pataki, B. A., Garriga, J., Eritja, R., Palmer, J. R. B., Bartumeus, F., & Csabai, I. (2021). Deep learning identification for citizen science surveillance of tiger mosquitoes. Scientific Reports, 11, 4718. https://doi.org/10.1038/s41598-021-83657-4

Zhao, D., Wang, X., Zhao, T., et al. (2022). A Swin Transformer-based model for mosquito species identification. Scientific Reports, 12, 18664. https://doi.org/10.1038/s41598-022-21017-6

–UNIVERSIDAD DEL VALLE DE GUATEMALA

DATA SCIENCE - 40

Erick Marroquin



Proyecto 2. Análisis Exploratorio
Identificación de Especies de Mosquitos

Ihan Marroquin - 23108
Diego Patzan - 23525
Milton Polanco - 23471

GUATEMALA, 10 de septiembre del 2026

Informe final

Situación problemática

La identificación correcta de mosquitos es relevante para la vigilancia entomológica y la salud pública, pero las fotografías obtenidas en proyectos de ciencia ciudadana no presentan condiciones uniformes. Pueden variar en resolución, encuadre, escala, fondo y posición del insecto. Además, el conjunto de datos analizado contiene clases con cantidades muy diferentes de ejemplos. Estas diferencias pueden introducir sesgos y afectar el desempeño de modelos de visión artificial si no se comprenden antes del entrenamiento.

El AI Mosquito Alert Challenge 2023 fue creado precisamente para mejorar la identificación de mosquitos mediante inteligencia artificial. El dataset oficial fue construido por el equipo y la comunidad de Mosquito Alert, colaboradores y miles de ciudadanos. Contiene 10,357 imágenes etiquetadas y un archivo annotations.csv con las dimensiones de cada imagen, las coordenadas de la caja delimitadora y la clase correspondiente [1].

Problema científico

¿Qué patrones, desequilibrios y posibles problemas de calidad presentan las imágenes, las clases y las cajas delimitadoras del dataset AI Mosquito Alert Challenge 2023, y qué implicaciones tienen para el posterior desarrollo de un modelo de identificación automática de mosquitos?

Objetivos

Objetivo general: analizar exploratoriamente el dataset AI Mosquito Alert Challenge 2023 para caracterizar la distribución de sus clases, las dimensiones de las imágenes, las cajas delimitadoras y la calidad de sus anotaciones.

- Describir las observaciones, variables y distribución de clases presentes en el conjunto de datos.
- Evaluar la calidad de los datos mediante la búsqueda de valores faltantes, registros duplicados, archivos inexistentes y cajas delimitadoras inválidas.
- Analizar las dimensiones de las imágenes y de los bounding boxes mediante estadística descriptiva, distribuciones, correlaciones y detección de valores atípicos.
- Comparar las características cuantitativas entre clases y visualizar ejemplos representativos de cada una.

Investigación breve del tema

Aunque el reto está relacionado con salud pública, no se trata de un problema de diagnóstico médico por imágenes: la imagen utilizada es la del mosquito y la tarea consiste en identificar su grupo taxonómico. Por ello, la investigación previa se enfocó en el valor epidemiológico de reconocer vectores. La OMS indica que Aedes aegypti es el principal vector del dengue y que otras especies del género Aedes también pueden actuar como vectores [2]. Por su parte, los CDC señalan que las hembras del género Anopheles pueden transmitir malaria [3]. Esto muestra por qué una herramienta automática de identificación puede ser útil para apoyar vigilancia, aunque el presente proyecto se limita al análisis exploratorio y no realiza diagnóstico de enfermedades.

Las seis etiquetas no tienen exactamente el mismo nivel taxonómico. Aedes aegypti y Aedes albopictus se identifican a nivel de especie; Anopheles, Culex y Culiseta se manejan a nivel de género; y japonicus-koreicus representa un complejo de Aedes japonicus/Aedes koreicus,

especies difíciles de diferenciar visualmente [1]. Este detalle debe tenerse presente al interpretar el término “identificación de especies”.

Análisis de los datos

El notebook se ejecutó de inicio a fin sin errores. Durante la ejecución se descargó el dataset oficial, se descomprimió, se verificó la correspondencia entre archivos y anotaciones, y se eliminó el ZIP de aproximadamente 10 GB para liberar espacio. Se confirmaron 10,357 imágenes y 10,357 registros en el CSV, por lo que existe correspondencia uno a uno entre ambos conjuntos.

Las preguntas principales del EDA fueron:

- ¿Las seis clases están balanceadas o existen especies/grupos con muy pocos ejemplos?
- ¿Qué variabilidad existe en el ancho, alto y área de las imágenes?
- ¿Qué proporción de cada fotografía ocupa el mosquito y cómo cambia entre clases?
- ¿Los mosquitos aparecen aproximadamente centrados o existe un sesgo de posición?
- ¿Qué relaciones existen entre el tamaño de la imagen y el tamaño del bounding box?
- ¿Existen faltantes, duplicados, cajas inválidas u outliers que deban revisarse antes de modelar?

Descripción de variables

Variable	Descripción	Tipo
img_fName	Nombre del archivo de imagen	Categórica / identificador
img_w	Ancho de la imagen en píxeles	Numérica
img_h	Alto de la imagen en píxeles	Numérica
bbx_xtl	Coordenada X superior izquierda	Numérica
bbx_ytl	Coordenada Y superior izquierda	Numérica
bbx_xbr	Coordenada X inferior derecha	Numérica
bbx_ybr	Coordenada Y inferior derecha	Numérica
class_label	Clase taxonómica asignada	Categórica

Las ocho variables originales se ampliaron durante el preprocesamiento con medidas derivadas como image_area, image_aspect_ratio, bbox_width, bbox_height, bbox_area, bbox_ratio y las coordenadas normalizadas del centro del bounding box. Estas variables permiten comparar imágenes de resoluciones distintas usando proporciones y no solamente valores en píxeles.

Limpieza y control de calidad

Revisión	Resultado	Decisión
Valores faltantes	0	No fue necesario imputar datos.
Filas duplicadas	0	No fue necesario eliminar registros repetidos.
Nombres de imagen duplicados	0	Cada nombre aparece una sola vez.
Imágenes faltantes respecto al CSV	0	Todos los registros tienen archivo.
Imágenes sin anotación	0	Todas las imágenes tienen registro.
Bounding boxes inválidos	3	Revisar/corregir antes de modelar.

Los tres registros inválidos comparten el mismo problema: la coordenada bbx_xbr supera el ancho real registrado de la imagen. No se corrigieron automáticamente porque una modificación sin inspección visual podría alterar la anotación original. Para una etapa de entrenamiento, estos casos deben revisarse y luego corregirse recortando la coordenada al límite válido únicamente si la imagen lo justifica, o excluirse si la anotación es incorrecta.

Imagen	Clase	img_w	bbx_xbr	Exceso X
train_09004.jpeg	culex	1024	1159	135
train_10156.jpeg	albopictus	1024	1312	288
train_10160.jpeg	culex	1816	2345	529

Distribución de las clases

Clase	Imágenes	Proporción	Mediana bbox/image
albopictus	4,612	44.53%	7.04%
culex	4,563	44.06%	6.61%
culiseta	622	6.01%	12.12%
japonicus-koreicus	429	4.14%	12.27%
anopheles	84	0.81%	10.23%
aegypti	47	0.45%	28.06%

El desbalance es el hallazgo más evidente del conjunto. Albopictus contiene 4,612 imágenes (44.53%) y Culex 4,563 (44.06%); juntas representan 88.59% del dataset. En el extremo contrario, Aegypti contiene solamente 47 imágenes (0.45%) y Anopheles 84 (0.81%). La relación entre la clase mayoritaria y la minoritaria es aproximadamente 98.13:1. Por lo tanto, una métrica global como accuracy podría ocultar un desempeño deficiente en las clases minoritarias.

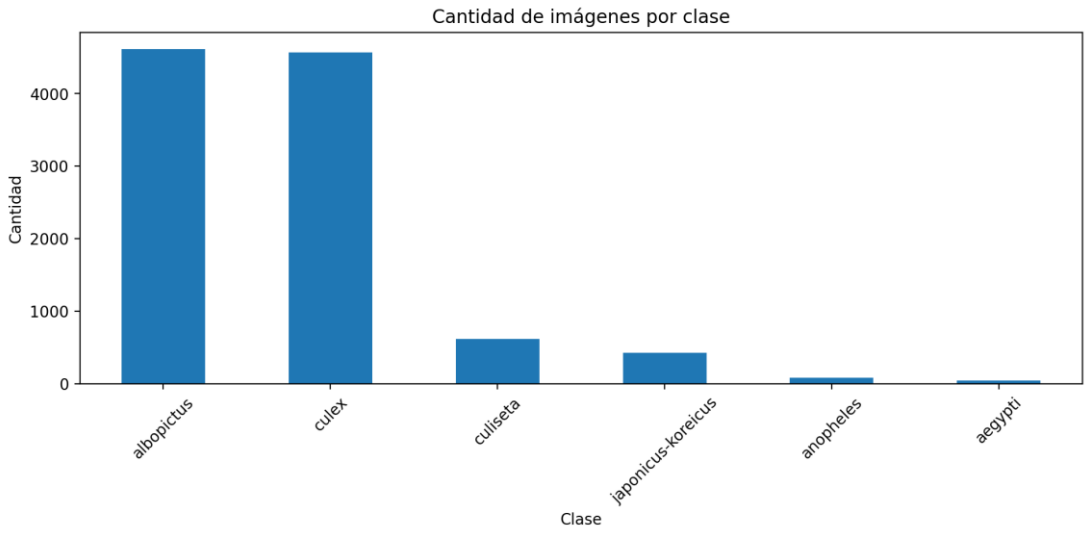


Figura 1. Distribución de imágenes entre las seis clases del dataset.

Ejemplos de las clases y variabilidad visual

La inspección visual confirma que las fotografías no siguen un entorno controlado. Cambian el fondo, la iluminación, el tamaño aparente del mosquito y el encuadre. En algunos casos el insecto ocupa buena parte de la fotografía y en otros aparece pequeño respecto al fondo. Esta variabilidad es esperable en datos de ciencia ciudadana y ayuda a explicar la dispersión observada en las variables de tamaño.

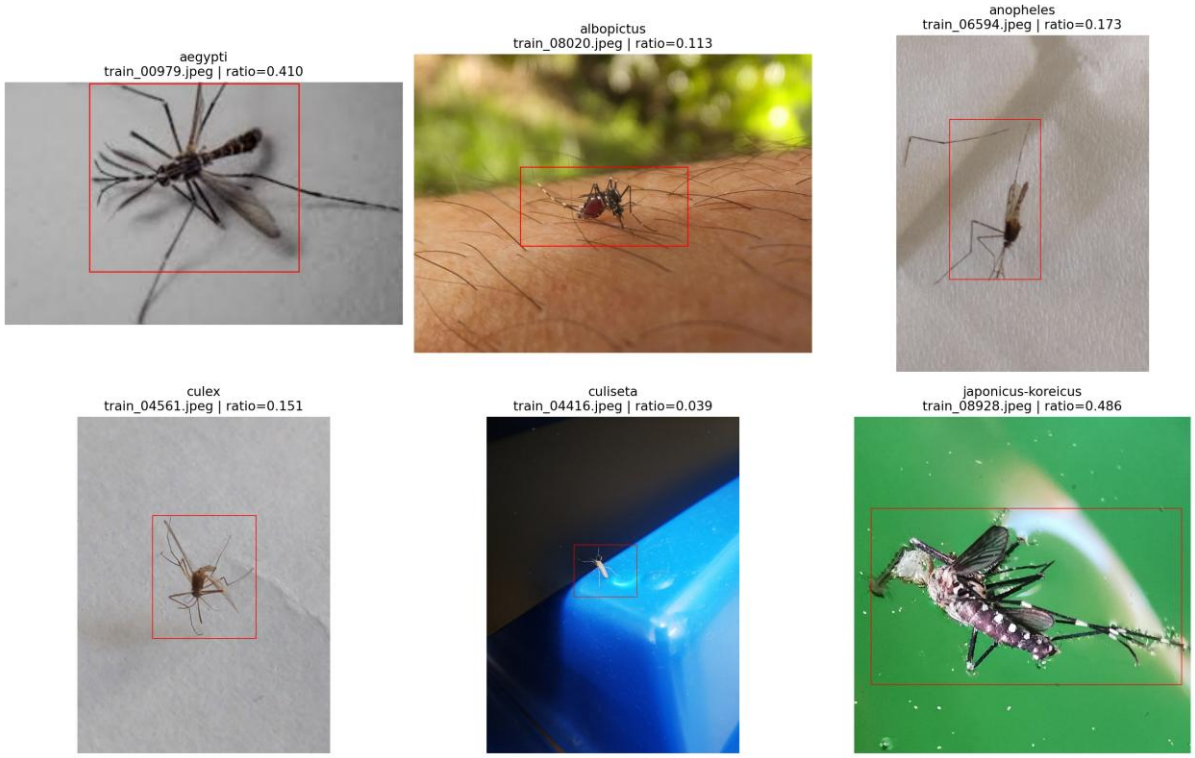


Figura 2. Ejemplos representativos de las seis clases con su bounding box.

Variables cuantitativas

Variable	Media	Mediana	Mínimo	Máximo
Ancho imagen	2,039.7	1,844.0	139.0	9,280.0
Alto imagen	2,470.5	2,208.0	106.0	12,000.0
Área imagen	6,261,127.0	3,773,952.0	16,112.0	108,000,000.0
Ancho bounding box	663.2	477.0	1.0	4,064.0
Alto bounding box	677.7	487.0	48.0	5,580.0
bbox_ratio	0.1314	0.0729	0.0000	0.9567

La resolución es muy variable. El ancho mediano es 1,844 píxeles y el alto mediano 2,208 píxeles, pero los valores van desde 139 hasta 9,280 píxeles de ancho y desde 106 hasta 12,000 de alto. Las medias son mayores que las medianas, especialmente en el área total, lo que indica presencia de imágenes de resolución muy alta que desplazan la distribución hacia la derecha.

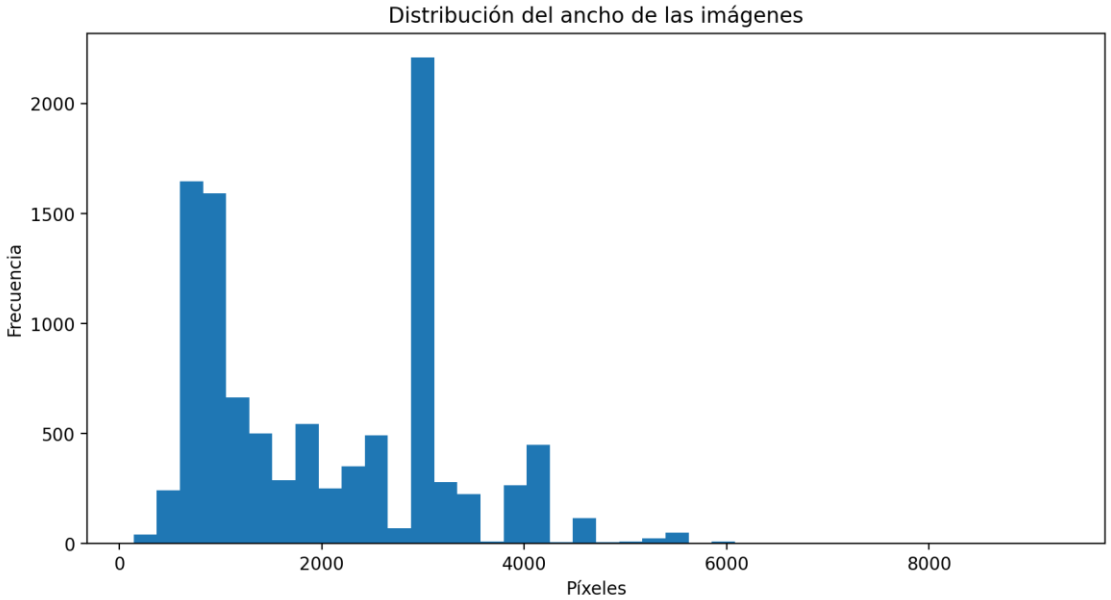


Figura 3. Histograma del ancho de las imágenes.

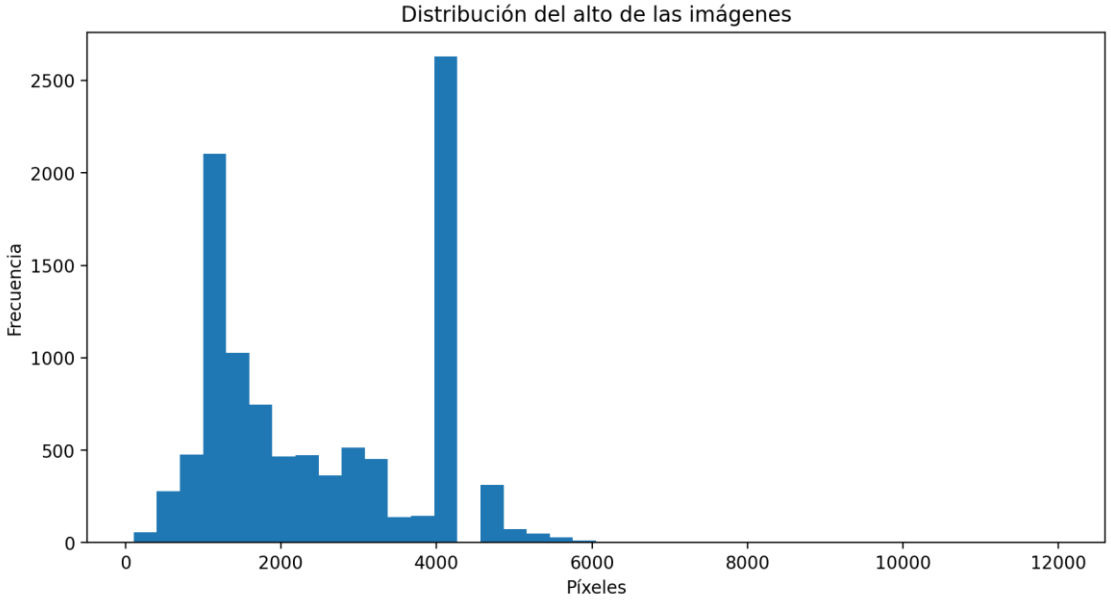


Figura 4. Histograma del alto de las imágenes.

Relación entre ancho y alto

El diagrama de dispersión muestra varios grupos de resoluciones repetidas y una tendencia positiva clara: las imágenes más anchas suelen ser también más altas. La correlación de Pearson entre img_w e img_h fue 0.77. Además, tanto el ancho como el alto se correlacionan fuertemente con el área total de la imagen (aproximadamente 0.91 en ambos casos), como era esperable por la relación matemática entre estas variables.

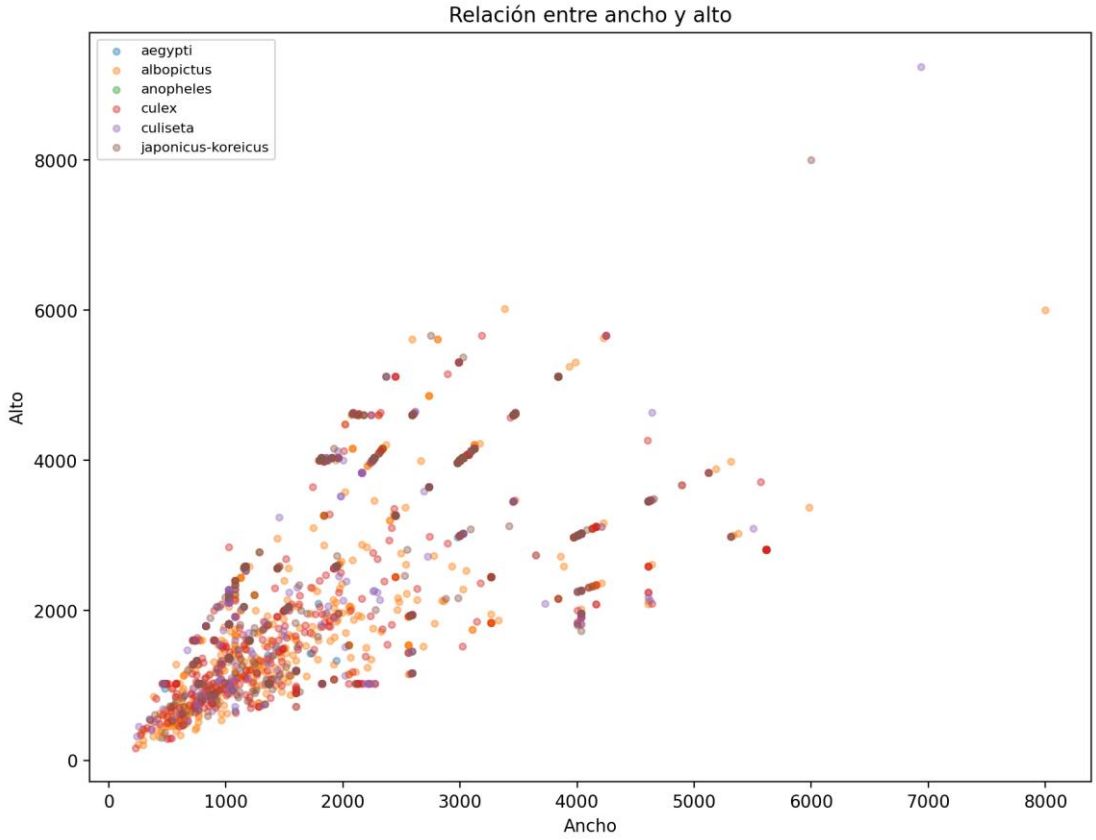


Figura 5. Relación entre el ancho y el alto de las imágenes, diferenciada por clase.

Tamaño relativo del mosquito

La variable bbox_ratio se definió como el área del bounding box dividida entre el área total de la imagen. Su mediana fue 0.0729, es decir, en una imagen típica la caja ocupa aproximadamente 7.29% del área. La media fue 13.14%, bastante mayor que la mediana, debido a una cola de casos donde el mosquito ocupa una porción muy grande de la fotografía. El valor mínimo fue aproximadamente 0.000005 y el máximo 0.9567.

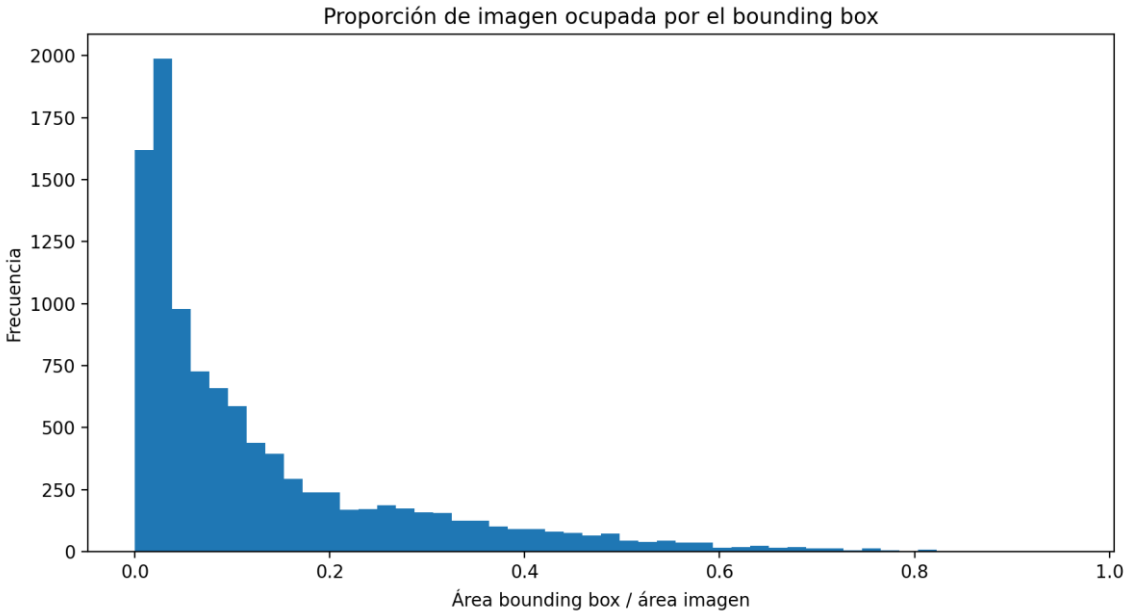


Figura 6. Distribución de la proporción de la imagen ocupada por el bounding box.

También existen diferencias entre clases. Aegypti presenta una mediana de 28.06% del área, mientras que Culex y Albopictus tienen medianas de 6.61% y 7.04%, respectivamente. Sin embargo, Aegypti tiene únicamente 47 observaciones, por lo que esta diferencia debe interpretarse con cautela: puede reflejar un patrón de captura del subconjunto disponible y no necesariamente una propiedad general de la especie.

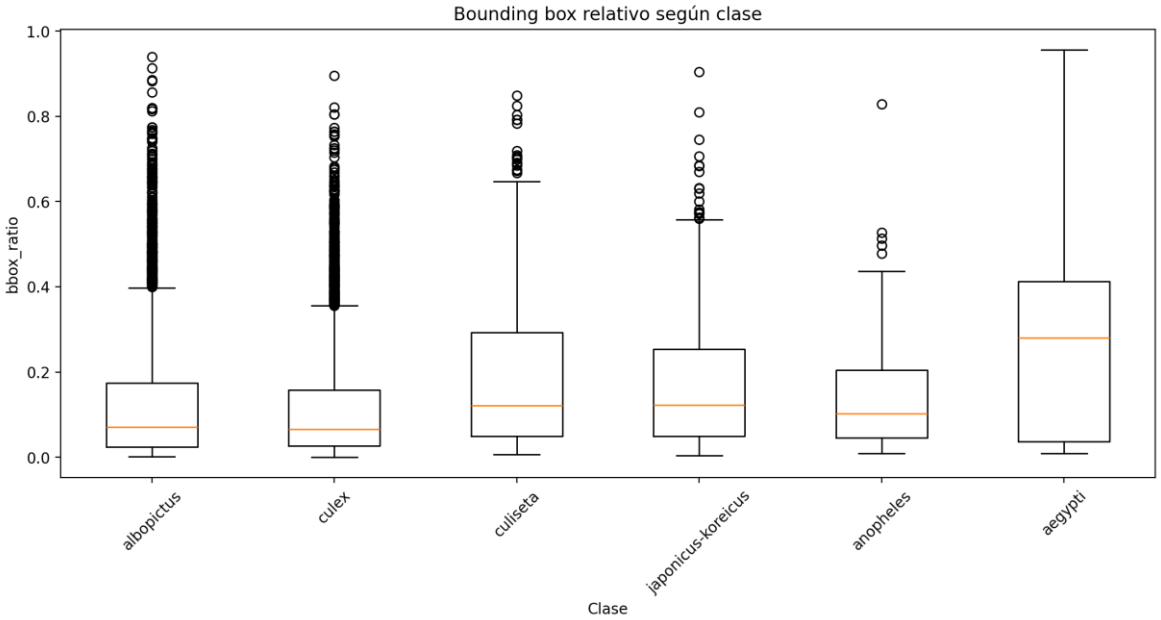


Figura 7. Distribución de bbox_ratio por clase y presencia de valores atípicos.

Outliers

Variable	Outliers IQR	Porcentaje
Ancho imagen	11	0.11%
Alto imagen	4	0.04%
Área imagen	18	0.17%
Ancho bbox	665	6.42%
Alto bbox	673	6.50%
Área bbox	1254	12.11%
bbox_ratio	729	7.04%

El criterio IQR identifica 729 outliers en bbox_ratio (7.04%) y 1,254 en bbox_area (12.11%). Estas observaciones no se eliminaron automáticamente. En un dataset de fotografías tomadas en condiciones reales, una imagen con un mosquito muy pequeño o muy cercano puede ser válida. Los extremos deben revisarse visualmente antes de decidir si representan errores, anotaciones poco confiables o ejemplos útiles de variación.

El caso más pequeño de bbox_ratio corresponde a train_07228.jpeg (Culex), con una proporción cercana a 0.000005, mientras que train_02259.jpeg (Aegypti) alcanza aproximadamente 0.9567. La amplitud entre ambos extremos confirma que la escala del objeto cambia de forma considerable dentro del dataset.

Posición del mosquito dentro de la imagen

Las coordenadas del centro del bounding box se normalizaron entre 0 y 1. El centro promedio fue (0.490, 0.496), prácticamente coincidente con el centro geométrico (0.5, 0.5). La nube de puntos se concentra alrededor de esa zona, por lo que existe una tendencia de encuadre central. Los pocos valores anómalos en X por encima del rango esperado están relacionados con los tres bounding boxes inválidos detectados.

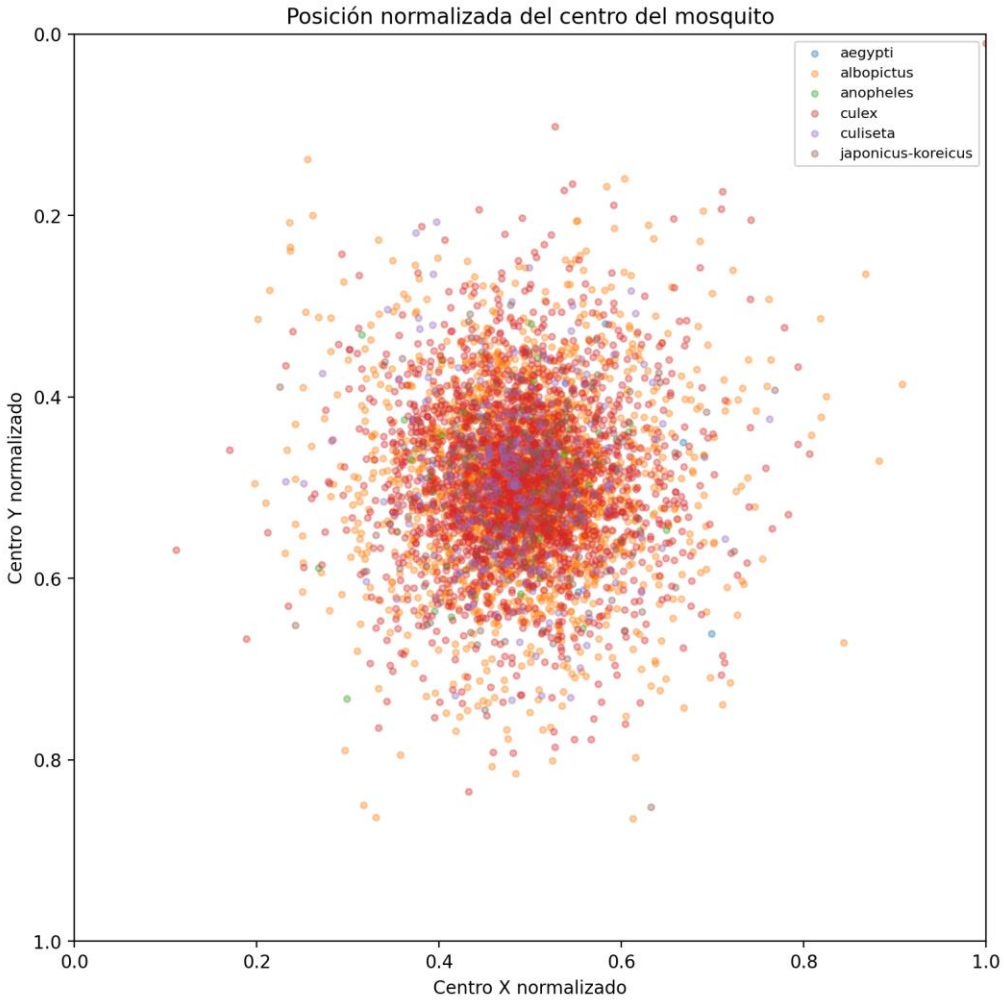


Figura 8. Posición normalizada del centro del mosquito dentro de la imagen.

Correlaciones entre variables

Las relaciones más fuertes se producen entre variables de tamaño. bbox_width y bbox_height tienen una correlación de 0.91; bbox_area se relaciona con ellas en 0.92 y 0.93, respectivamente. bbox_ratio presenta correlaciones moderadas con bbox_width (0.56), bbox_height (0.58) y bbox_area (0.57). En cambio, su relación con el ancho y alto de la imagen es ligeramente negativa (-0.10 y -0.14), lo que sugiere que una mayor resolución total no implica que el mosquito ocupe una fracción mayor de la fotografía.

Las posiciones normalizadas X e Y tienen correlaciones cercanas a cero con las variables de tamaño. Esto indica que, dentro de este análisis lineal, el tamaño del mosquito no depende de que aparezca más hacia un lado, arriba o abajo de la fotografía.

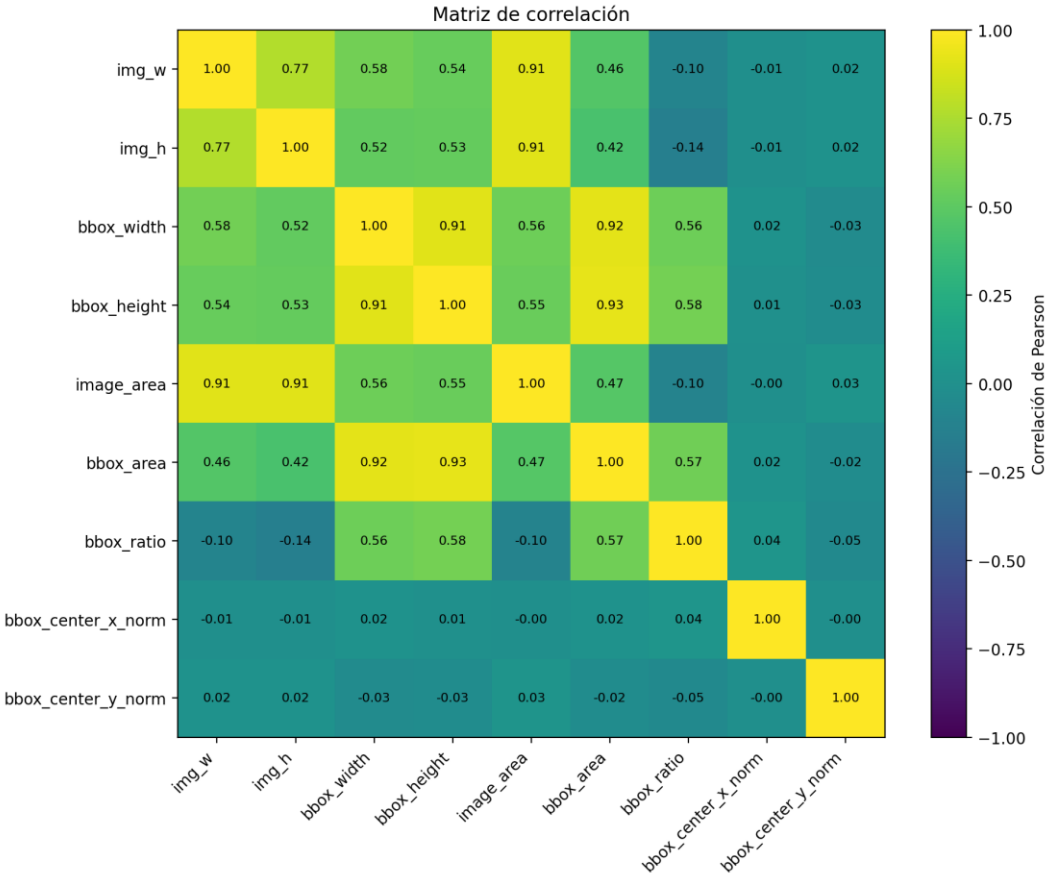


Figura 9. Matriz de correlación de Pearson para las principales variables cuantitativas.

Decisiones de preprocesamiento

- No se realizó imputación porque no existen valores faltantes.
- No se eliminaron filas por duplicación porque no se encontraron duplicados exactos ni nombres repetidos.
- Se conservaron los outliers para el análisis; su eliminación requeriría revisión visual individual.
- Se identificaron tres bounding boxes fuera del ancho de la imagen. Estos deben corregirse o excluirse antes de entrenar un detector.
- Se crearon variables normalizadas y proporcionales para comparar imágenes con resoluciones diferentes.
- El fuerte desbalance de clases debe considerarse al construir particiones de entrenamiento/validación y al seleccionar métricas de evaluación.

Hallazgos principales

- El dataset contiene 10,357 imágenes, seis clases y ocho variables originales; el notebook añadió variables derivadas para estudiar tamaño y posición.
- Albopictus y Culex concentran 88.59% de todas las imágenes. Aegypti representa solo 0.45%, por lo que el conjunto está fuertemente desbalanceado.
- No se detectaron valores faltantes, registros duplicados, imágenes faltantes ni archivos sin anotación.
- Se detectaron tres bounding boxes inválidos porque su coordenada derecha supera el ancho de la imagen.

- El mosquito ocupa una mediana de 7.29% del área de la imagen, pero la distribución es muy dispersa y llega hasta 95.67%.
- Las fotografías presentan gran variabilidad de resolución, con imágenes desde tamaños muy pequeños hasta resoluciones superiores a 9,000 x 12,000 píxeles.
- Los centros de los bounding boxes se agrupan cerca del centro de la imagen, con promedio normalizado de (0.490, 0.496).
- Las correlaciones fuertes corresponden principalmente a relaciones geométricas entre ancho, alto y área; la posición del mosquito tiene correlaciones prácticamente nulas con el tamaño.

Conclusiones

- El conjunto de datos es consistente en términos de completitud: las 10,357 anotaciones cuentan con su imagen correspondiente y no se encontraron valores faltantes ni duplicados.
- El principal reto para una futura fase de modelado es el desbalance. Una división estratificada es necesaria, pero por sí sola no resuelve que Aegypti y Anopheles tengan muy pocos ejemplos. Se deberían considerar ponderación de clases, aumentación cuidadosamente diseñada y métricas macro o por clase.
- La variación de resolución y escala es amplia. Un modelo deberá usar un esquema de redimensionamiento coherente y conservar la relación de aspecto para evitar deformar la morfología del mosquito.
- La proporción ocupada por el mosquito cambia mucho entre fotografías y entre clases. Esto vuelve importante que la detección tolere tanto objetos pequeños como primeros planos.
- Los 729 outliers de bbox_ratio no deben considerarse errores de forma automática; el análisis muestra que parte de la variabilidad puede provenir de las condiciones de captura. Sin embargo, los tres bounding boxes fuera de límites sí requieren una decisión de limpieza explícita antes de entrenar.
- La tendencia a ubicar el mosquito cerca del centro puede ser útil para comprender el dataset, pero también representa un posible sesgo de encuadre que un modelo no debería asumir como condición necesaria en imágenes nuevas.
- El EDA permite concluir que el dataset es utilizable para una siguiente etapa de visión artificial, siempre que se atiendan el desbalance, las tres anotaciones inválidas y la variabilidad de escala durante el preprocesamiento y la evaluación.

Reproducibilidad

El análisis se realizó en Google Colab con el notebook Proyecto_2_MosquitoAlert.ipynb. Todas las celdas de código se ejecutaron sin errores. El dataset se descargó desde la publicación oficial de Mosquito Alert en Hugging Face, se descomprimió en el almacenamiento temporal de Colab y el ZIP original se eliminó después de verificar 10,357 imágenes y 10,357 registros. Las tablas, figuras y hallazgos se exportaron a resultados_eda.zip, con un tamaño final aproximado de 4.33 MB. El dataset oficial se distribuye bajo licencia CC BY-NC-SA 4.0 [1].

Referencias

[1] Bartumeus, F., Falk, M., Garriga, J. y Mosquito Alert Expert Community. AI Mosquito Alert Challenge Dataset 2023. Zenodo. https://doi.org/10.5281/zenodo.15063886

[2] World Health Organization. Dengue and severe dengue. https://www.who.int/news-room/fact-sheets/detail/dengue-and-severe-dengue

[3] Centers for Disease Control and Prevention. How Malaria Spreads. https://www.cdc.gov/malaria/causes/

[4] Mosquito Alert. AI Mosquito Alert Challenge 2023 dataset. https://huggingface.co/datasets/mosquito-alert/ai-mosquito-alert-challenge-2023