

–UNIVERSIDAD DEL VALLE DE GUATEMALA

DATA SCIENCE - 40

Erick Marroquin



Proyecto 2. Análisis Exploratorio Identificación de Especies de Mosquitos

Ihan Marroquin - 23108

Diego Patzan - 23525

Milton Polanco - 23471

GUATEMALA, 10 de septiembre del 2026

Informe final

Situación problemática

La identificación correcta de mosquitos es relevante para la vigilancia entomológica y la salud pública, pero las fotografías obtenidas en proyectos de ciencia ciudadana no presentan condiciones uniformes. Pueden variar en resolución, encuadre, escala, fondo y posición del insecto. Además, el conjunto de datos analizado contiene clases con cantidades muy diferentes de ejemplos. Estas diferencias pueden introducir sesgos y afectar el desempeño de modelos de visión artificial si no se comprenden antes del entrenamiento.

El AI Mosquito Alert Challenge 2023 fue creado precisamente para mejorar la identificación de mosquitos mediante inteligencia artificial. El dataset oficial fue construido por el equipo y la comunidad de Mosquito Alert, colaboradores y miles de ciudadanos. Contiene 10,357 imágenes etiquetadas y un archivo annotations.csv con las dimensiones de cada imagen, las coordenadas de la caja delimitadora y la clase correspondiente [1].

Problema científico

¿Qué patrones, desequilibrios y posibles problemas de calidad presentan las imágenes, las clases y las cajas delimitadoras del dataset AI Mosquito Alert Challenge 2023, y qué implicaciones tienen para el posterior desarrollo de un modelo de identificación automática de mosquitos?

Objetivos

Objetivo general: analizar exploratoriamente el dataset AI Mosquito Alert Challenge 2023 para caracterizar la distribución de sus clases, las dimensiones de las imágenes, las cajas delimitadoras y la calidad de sus anotaciones.

- Describir las observaciones, variables y distribución de clases presentes en el conjunto de datos.
- Evaluar la calidad de los datos mediante la búsqueda de valores faltantes, registros duplicados, archivos inexistentes y cajas delimitadoras inválidas.
- Analizar las dimensiones de las imágenes y de los bounding boxes mediante estadística descriptiva, distribuciones, correlaciones y detección de valores atípicos.
- Comparar las características cuantitativas entre clases y visualizar ejemplos representativos de cada una.

Investigación breve del tema

Aunque el reto está relacionado con salud pública, no se trata de un problema de diagnóstico médico por imágenes: la imagen utilizada es la del mosquito y la tarea consiste en identificar su grupo taxonómico. Por ello, la investigación previa se enfocó en el valor epidemiológico de reconocer vectores. La OMS indica que *Aedes aegypti* es el principal vector del dengue y que otras especies del género *Aedes* también pueden actuar como vectores [2]. Por su parte, los CDC señalan que las hembras del género *Anopheles* pueden transmitir malaria [3]. Esto muestra por qué una herramienta automática de identificación puede ser útil para apoyar vigilancia, aunque el presente proyecto se limita al análisis exploratorio y no realiza diagnóstico de enfermedades.

Las seis etiquetas no tienen exactamente el mismo nivel taxonómico. *Aedes aegypti* y *Aedes albopictus* se identifican a nivel de especie; *Anopheles*, *Culex* y *Culiseta* se manejan a nivel de género; y *japonicus-koreicus* representa un complejo de *Aedes japonicus*/*Aedes koreicus*,

especies difíciles de diferenciar visualmente [1]. Este detalle debe tenerse presente al interpretar el término “identificación de especies”.

Análisis de los datos

El notebook se ejecutó de inicio a fin sin errores. Durante la ejecución se descargó el dataset oficial, se descomprimió, se verificó la correspondencia entre archivos y anotaciones, y se eliminó el ZIP de aproximadamente 10 GB para liberar espacio. Se confirmaron 10,357 imágenes y 10,357 registros en el CSV, por lo que existe correspondencia uno a uno entre ambos conjuntos.

Las preguntas principales del EDA fueron:

- ¿Las seis clases están balanceadas o existen especies/grupos con muy pocos ejemplos?
- ¿Qué variabilidad existe en el ancho, alto y área de las imágenes?
- ¿Qué proporción de cada fotografía ocupa el mosquito y cómo cambia entre clases?
- ¿Los mosquitos aparecen aproximadamente centrados o existe un sesgo de posición?
- ¿Qué relaciones existen entre el tamaño de la imagen y el tamaño del bounding box?
- ¿Existen faltantes, duplicados, cajas inválidas u outliers que deban revisarse antes de modelar?

Descripción de variables

Variable	Descripción	Tipo
img_fName	Nombre del archivo de imagen	Categórica / identificador
img_w	Ancho de la imagen en píxeles	Numérica
img_h	Alto de la imagen en píxeles	Numérica
bbx_xtl	Coordenada X superior izquierda	Numérica
bbx_ytl	Coordenada Y superior izquierda	Numérica
bbx_xbr	Coordenada X inferior derecha	Numérica
bbx_ybr	Coordenada Y inferior derecha	Numérica
class_label	Clase taxonómica asignada	Categórica

Las ocho variables originales se ampliaron durante el preprocesamiento con medidas derivadas como `image_area`, `image_aspect_ratio`, `bbox_width`, `bbox_height`, `bbox_area`, `bbox_ratio` y las coordenadas normalizadas del centro del bounding box. Estas variables permiten comparar imágenes de resoluciones distintas usando proporciones y no solamente valores en píxeles.

Limpieza y control de calidad

Revisión	Resultado	Decisión
Valores faltantes	0	No fue necesario imputar datos.
Filas duplicadas	0	No fue necesario eliminar registros repetidos.
Nombres de imagen duplicados	0	Cada nombre aparece una sola vez.
Imágenes faltantes respecto al CSV	0	Todos los registros tienen archivo.
Imágenes sin anotación	0	Todas las imágenes tienen registro.
Bounding boxes inválidos	3	Revisar/corregir antes de modelar.

Los tres registros inválidos comparten el mismo problema: la coordenada `bbx_xbr` supera el ancho real registrado de la imagen. No se corrigieron automáticamente porque una modificación sin inspección visual podría alterar la anotación original. Para una etapa de entrenamiento, estos casos deben revisarse y luego corregirse recortando la coordenada al límite válido únicamente si la imagen lo justifica, o excluirse si la anotación es incorrecta.

Imagen	Clase	img_w	bbx_xbr	Exceso X
train_09004.jpeg	culex	1024	1159	135
train_10156.jpeg	albopictus	1024	1312	288
train_10160.jpeg	culex	1816	2345	529

Distribución de las clases

Clase	Imágenes	Proporción	Mediana bbox/image
albopictus	4,612	44.53%	7.04%
culex	4,563	44.06%	6.61%
culiseta	622	6.01%	12.12%
japonicus-koreicus	429	4.14%	12.27%
anopheles	84	0.81%	10.23%
aegypti	47	0.45%	28.06%

El desbalance es el hallazgo más evidente del conjunto. *Albopictus* contiene 4,612 imágenes (44.53%) y *Culex* 4,563 (44.06%); juntas representan 88.59% del dataset. En el extremo contrario, *Aegypti* contiene solamente 47 imágenes (0.45%) y *Anopheles* 84 (0.81%). La relación entre la clase mayoritaria y la minoritaria es aproximadamente 98.13:1. Por lo tanto, una métrica global como *accuracy* podría ocultar un desempeño deficiente en las clases minoritarias.




Figura 1. Distribución de imágenes entre las seis clases del dataset.

Ejemplos de las clases y variabilidad visual

La inspección visual confirma que las fotografías no siguen un entorno controlado. Cambian el fondo, la iluminación, el tamaño aparente del mosquito y el encuadre. En algunos casos el insecto ocupa buena parte de la fotografía y en otros aparece pequeño respecto al fondo. Esta variabilidad es esperable en datos de ciencia ciudadana y ayuda a explicar la dispersión observada en las variables de tamaño.




Figura 2. Ejemplos representativos de las seis clases con su bounding box.

Variables cuantitativas

Variable	Media	Mediana	Mínimo	Máximo
Ancho imagen	2,039.7	1,844.0	139.0	9,280.0
Alto imagen	2,470.5	2,208.0	106.0	12,000.0
Área imagen	6,261,127.0	3,773,952.0	16,112.0	108,000,000.0
Ancho bounding box	663.2	477.0	1.0	4,064.0
Alto bounding box	677.7	487.0	48.0	5,580.0
bbox_ratio	0.1314	0.0729	0.0000	0.9567

La resolución es muy variable. El ancho mediano es 1,844 píxeles y el alto mediano 2,208 píxeles, pero los valores van desde 139 hasta 9,280 píxeles de ancho y desde 106 hasta 12,000 de alto. Las medias son mayores que las medianas, especialmente en el área total, lo que indica presencia de imágenes de resolución muy alta que desplazan la distribución hacia la derecha.




Figura 3. Histograma del ancho de las imágenes.




Figura 4. Histograma del alto de las imágenes.

Relación entre ancho y alto

El diagrama de dispersión muestra varios grupos de resoluciones repetidas y una tendencia positiva clara: las imágenes más anchas suelen ser también más altas. La correlación de Pearson entre `img_w` e `img_h` fue 0.77. Además, tanto el ancho como el alto se correlacionan fuertemente con el área total de la imagen (aproximadamente 0.91 en ambos casos), como era esperable por la relación matemática entre estas variables.




Figura 5. Relación entre el ancho y el alto de las imágenes, diferenciada por clase.

Tamaño relativo del mosquito

La variable `bbox_ratio` se definió como el área del bounding box dividida entre el área total de la imagen. Su mediana fue 0.0729, es decir, en una imagen típica la caja ocupa aproximadamente 7.29% del área. La media fue 13.14%, bastante mayor que la mediana, debido a una cola de casos donde el mosquito ocupa una porción muy grande de la fotografía. El valor mínimo fue aproximadamente 0.000005 y el máximo 0.9567.




Figura 6. Distribución de la proporción de la imagen ocupada por el bounding box.

También existen diferencias entre clases. Aegypti presenta una mediana de 28.06% del área, mientras que Culex y Albopictus tienen medianas de 6.61% y 7.04%, respectivamente. Sin embargo, Aegypti tiene únicamente 47 observaciones, por lo que esta diferencia debe interpretarse con cautela: puede reflejar un patrón de captura del subconjunto disponible y no necesariamente una propiedad general de la especie.




Figura 7. Distribución de `bbox_ratio` por clase y presencia de valores atípicos.

Outliers

Variable	Outliers IQR	Porcentaje
Ancho imagen	11	0.11%
Alto imagen	4	0.04%
Área imagen	18	0.17%
Ancho bbox	665	6.42%
Alto bbox	673	6.50%
Área bbox	1254	12.11%
<code>bbox_ratio</code>	729	7.04%

El criterio IQR identifica 729 outliers en `bbox_ratio` (7.04%) y 1,254 en `bbox_area` (12.11%). Estas observaciones no se eliminaron automáticamente. En un dataset de fotografías tomadas en condiciones reales, una imagen con un mosquito muy pequeño o muy cercano puede ser válida. Los extremos deben revisarse visualmente antes de decidir si representan errores, anotaciones poco confiables o ejemplos útiles de variación.

El caso más pequeño de `bbox_ratio` corresponde a `train_07228.jpeg` (Culex), con una proporción cercana a 0.000005, mientras que `train_02259.jpeg` (Aegypti) alcanza aproximadamente 0.9567. La amplitud entre ambos extremos confirma que la escala del objeto cambia de forma considerable dentro del dataset.

Posición del mosquito dentro de la imagen

Las coordenadas del centro del bounding box se normalizaron entre 0 y 1. El centro promedio fue (0.490, 0.496), prácticamente coincidente con el centro geométrico (0.5, 0.5). La nube de puntos se concentra alrededor de esa zona, por lo que existe una tendencia de encuadre central. Los pocos valores anómalos en X por encima del rango esperado están relacionados con los tres bounding boxes inválidos detectados.




Figura 8. Posición normalizada del centro del mosquito dentro de la imagen.

Correlaciones entre variables

Las relaciones más fuertes se producen entre variables de tamaño. `bbox_width` y `bbox_height` tienen una correlación de 0.91; `bbox_area` se relaciona con ellas en 0.92 y 0.93, respectivamente. `bbox_ratio` presenta correlaciones moderadas con `bbox_width` (0.56), `bbox_height` (0.58) y `bbox_area` (0.57). En cambio, su relación con el ancho y alto de la imagen es ligeramente negativa (-0.10 y -0.14), lo que sugiere que una mayor resolución total no implica que el mosquito ocupe una fracción mayor de la fotografía.

Las posiciones normalizadas X e Y tienen correlaciones cercanas a cero con las variables de tamaño. Esto indica que, dentro de este análisis lineal, el tamaño del mosquito no depende de que aparezca más hacia un lado, arriba o abajo de la fotografía.




Figura 9. Matriz de correlación de Pearson para las principales variables cuantitativas.

Decisiones de preprocesamiento

- No se realizó imputación porque no existen valores faltantes.
- No se eliminaron filas por duplicación porque no se encontraron duplicados exactos ni nombres repetidos.
- Se conservaron los outliers para el análisis; su eliminación requeriría revisión visual individual.
- Se identificaron tres bounding boxes fuera del ancho de la imagen. Estos deben corregirse o excluirse antes de entrenar un detector.
- Se crearon variables normalizadas y proporcionales para comparar imágenes con resoluciones diferentes.
- El fuerte desbalance de clases debe considerarse al construir particiones de entrenamiento/validación y al seleccionar métricas de evaluación.

Hallazgos principales

- El dataset contiene 10,357 imágenes, seis clases y ocho variables originales; el notebook añadió variables derivadas para estudiar tamaño y posición.
- Albopictus y Culex concentran 88.59% de todas las imágenes. Aegypti representa solo 0.45%, por lo que el conjunto está fuertemente desbalanceado.
- No se detectaron valores faltantes, registros duplicados, imágenes faltantes ni archivos sin anotación.
- Se detectaron tres bounding boxes inválidos porque su coordenada derecha supera el ancho de la imagen.

- El mosquito ocupa una mediana de 7.29% del área de la imagen, pero la distribución es muy dispersa y llega hasta 95.67%.
- Las fotografías presentan gran variabilidad de resolución, con imágenes desde tamaños muy pequeños hasta resoluciones superiores a 9,000 x 12,000 píxeles.
- Los centros de los bounding boxes se agrupan cerca del centro de la imagen, con promedio normalizado de (0.490, 0.496).
- Las correlaciones fuertes corresponden principalmente a relaciones geométricas entre ancho, alto y área; la posición del mosquito tiene correlaciones prácticamente nulas con el tamaño.

Conclusiones

- El conjunto de datos es consistente en términos de completitud: las 10,357 anotaciones cuentan con su imagen correspondiente y no se encontraron valores faltantes ni duplicados.
- El principal reto para una futura fase de modelado es el desbalance. Una división estratificada es necesaria, pero por sí sola no resuelve que *Aegypti* y *Anopheles* tengan muy pocos ejemplos. Se deberían considerar ponderación de clases, aumentación cuidadosamente diseñada y métricas macro o por clase.
- La variación de resolución y escala es amplia. Un modelo deberá usar un esquema de redimensionamiento coherente y conservar la relación de aspecto para evitar deformar la morfología del mosquito.
- La proporción ocupada por el mosquito cambia mucho entre fotografías y entre clases. Esto vuelve importante que la detección tolere tanto objetos pequeños como primeros planos.
- Los 729 outliers de `bbox_ratio` no deben considerarse errores de forma automática; el análisis muestra que parte de la variabilidad puede provenir de las condiciones de captura. Sin embargo, los tres bounding boxes fuera de límites sí requieren una decisión de limpieza explícita antes de entrenar.
- La tendencia a ubicar el mosquito cerca del centro puede ser útil para comprender el dataset, pero también representa un posible sesgo de encuadre que un modelo no debería asumir como condición necesaria en imágenes nuevas.
- El EDA permite concluir que el dataset es utilizable para una siguiente etapa de visión artificial, siempre que se atiendan el desbalance, las tres anotaciones inválidas y la variabilidad de escala durante el preprocesamiento y la evaluación.

Reproducibilidad

El análisis se realizó en Google Colab con el notebook `Proyecto_2_MosquitoAlert.ipynb`. Todas las celdas de código se ejecutaron sin errores. El dataset se descargó desde la publicación oficial de Mosquito Alert en Hugging Face, se descomprimió en el almacenamiento temporal de Colab y el ZIP original se eliminó después de verificar 10,357 imágenes y 10,357 registros. Las tablas, figuras y hallazgos se exportaron a `resultados_eda.zip`, con un tamaño final aproximado de 4.33 MB. El dataset oficial se distribuye bajo licencia CC BY-NC-SA 4.0 [1].

Referencias

[1] Bartumeus, F., Falk, M., Garriga, J. y Mosquito Alert Expert Community. AI Mosquito Alert Challenge Dataset 2023. Zenodo. <https://doi.org/10.5281/zenodo.15063886>

- [2] World Health Organization. Dengue and severe dengue. <https://www.who.int/news-room/fact-sheets/detail/dengue-and-severe-dengue>
- [3] Centers for Disease Control and Prevention. How Malaria Spreads. <https://www.cdc.gov/malaria/causes/>
- [4] Mosquito Alert. AI Mosquito Alert Challenge 2023 dataset. <https://huggingface.co/datasets/mosquito-alert/ai-mosquito-alert-challenge-2023>